

B4. Calculus

Bổ sung cho bài giảng

2019

Nội dung bổ sung



1. Đạo hàm và tích phân
2. Gradient Descent



1. Đạo hàm và tích phân

□ Dãy số (*sequence*)

$$f : N \rightarrow R$$

$$x_n = f(n)$$

$$\{x_n\}_n \equiv \{x_n\} \equiv x_1, x_2, x_3, \dots, x_n, \dots$$

□ Giới hạn của dãy số (hội tụ)

$$\lim_{n \rightarrow \infty} x_n = a \quad x_n \rightarrow a, n \rightarrow \infty$$

$$\forall (\varepsilon > 0), \exists n_0 : \forall n \geq n_0 : |x_n - a| < \varepsilon$$



1. Đạo hàm và tích phân (tt.)

□ Một số tính chất cơ bản của giới hạn

- Mọi dãy hội tụ đều có giới hạn duy nhất
- Mọi dãy hội tụ đều bị chặn
- Giả sử: $\lim_{n \rightarrow \infty} x_n = a, \lim_{n \rightarrow \infty} y_n = b$. Ta có:

$$(i) \lim_{n \rightarrow \infty} (x_n + y_n) = a + b$$

$$(ii) \lim_{n \rightarrow \infty} (c + x_n) = c + a$$

$$(iii) \lim_{n \rightarrow \infty} (c \cdot x_n) = c \cdot a$$

$$(iv) \lim_{n \rightarrow \infty} (x_n \cdot y_n) = a \cdot b$$

$$(v) \lim_{n \rightarrow \infty} \left(\frac{x_n}{y_n} \right) = \frac{a}{b}, y_n \neq 0, b \neq 0$$



1. Đạo hàm và tích phân (tt.)

□ Giới hạn của hàm số

- A là lân cận của $x_0 \in \mathbb{R}$: $\exists(\delta > 0): (x_0 - \delta, x_0 + \delta) \subset A$
- Hàm số $y = f(x)$ xác định trên lân cận A của x_0

$$\lim_{x \rightarrow x_0} f(x) = L \quad f(x) \rightarrow L, x \rightarrow x_0$$

$$\forall(\varepsilon > 0), \exists(\delta > 0):$$

$$\forall |x - x_0| < \delta \Rightarrow |f(x) - L| < \varepsilon$$

□ Giả sử $f(x)$ xác định trên A . Hàm $f(x)$ liên tục tại $x_0 \in A$:

$$\lim_{x \rightarrow x_0} f(x) = f(x_0)$$

$$\forall(\varepsilon > 0), \exists(\delta > 0):$$

$$\forall |x - x_0| < \delta \Rightarrow |f(x) - f(x_0)| < \varepsilon$$

- Hàm $f(x)$ liên tục trên A nếu $f(x)$ liên tục tại mọi $x \in A$



1. Đạo hàm và tích phân (tt.)

□ Một số tính chất cơ bản của đạo hàm

- Nếu f có đạo hàm tại x_0 thì f liên tục tại x_0
- Giả sử $f(x), g(x)$ có đạo hàm tại x . Ta có:

$$(i) \quad (a.f + b.g)'(x) = a.f'(x) + b.g'(x)$$

$$(ii) \quad (f.g)'(x) = f'(x).g(x) + g'(x).f(x)$$

$$(iii) \quad \left(\frac{f}{g} \right)'(x) = \frac{f'(x).g(x) - g'(x).f(x)}{g^2(x)}$$

$$(iv) \quad (f \circ g)'(x) = f'(g(x)).g'(x)$$



1. Đạo hàm và tích phân (tt.)

□ Đạo hàm của một số hàm sơ cấp

- 1) $f(x) = a \Rightarrow f'(x) = 0$
- 2) $f(x) = x \Rightarrow f'(x) = 1$
- 3) $f(x) = x^\alpha, \alpha \in \mathbb{R} \setminus \{-1\} \Rightarrow f'(x) = \alpha \cdot x^{(\alpha-1)}$
- 4) $f(x) = \frac{1}{x} \Rightarrow f'(x) = \frac{-1}{x^2}$
- 5) $f(x) = a^x, a > 0 \Rightarrow f'(x) = \frac{1}{x \cdot \ln(a)}$
- 6) $f(x) = e^x \Rightarrow f'(x) = e^x$
- 7) $f(x) = \log_a(x), a > 0 \Rightarrow f'(x) = \frac{1}{a^x \cdot \ln(a)}$
- 8) $f(x) = \ln(x) \Rightarrow f'(x) = \frac{1}{x}$
- 9) $f(x) = \sin(x) \Rightarrow f'(x) = \cos(x)$
- 10) $f(x) = \cos(x) \Rightarrow f'(x) = -\sin(x)$




53



1. Đạo hàm và tích phân (tt.)

□ Tích phân xác định



54



1. Đạo hàm và tích phân


2. Gradient Descent

2. Gradient Descent



□ Hồi quy tuyến tính (*linear regression*)

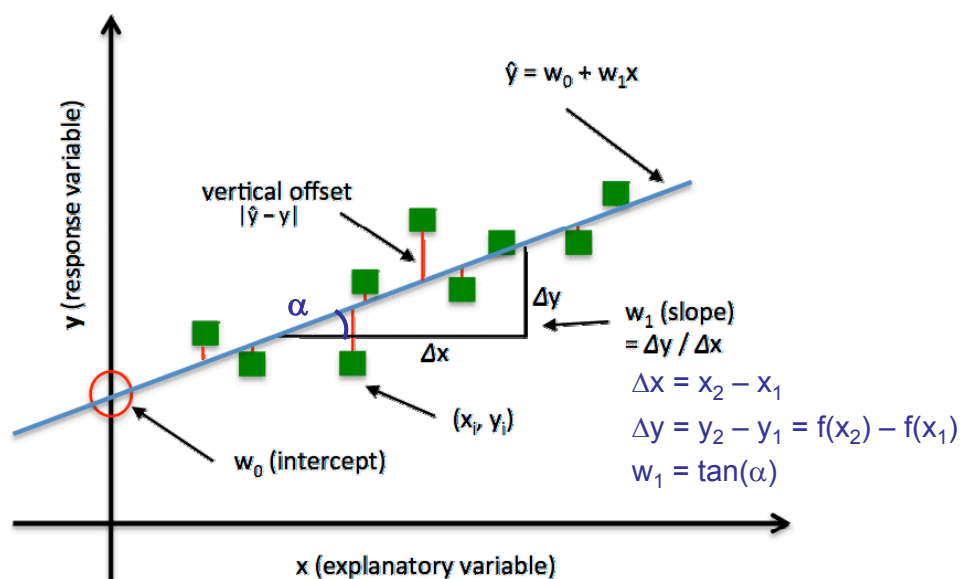
- tên khác: *linear fitting*, *linear least square*



2. Gradient Descent (tt.)



□ Hồi quy tuyến tính (linear regression)



2. Gradient Descent (tt.)



□ Thuật toán Gradient Descent


- local/global minimum (maximum): $f'(x_0) = 0$
- vòng lặp tìm optimal point x^* tiến gần đến x_0 (local minimum)
 - $f'(x^{(t)}) > 0$: $x^{(t)}$ ở bên PHẢI của $x_0 \Rightarrow$ cần lùi sang TRÁI (A)
 - $f'(x^{(t)}) < 0$: $x^{(t)}$ ở bên TRÁI của $x_0 \Rightarrow$ cần tiến sang PHẢI (B)

Tóm lại: $x^{(t)}$ cần di chuyển NGƯỢC DẤU với đạo hàm $\rightarrow x_0$

$$x^{(t+1)} = x^{(t)} - \rho \cdot f'(x^{(t)})$$

$$\theta^{(t+1)} = \theta^{(t)} - \rho \cdot \frac{\partial f(\theta^{(t)})}{\partial \theta^{(t)}}$$

$\rho > 0$: **learning rate** (tốc độ học)





2. Gradient Descent (tt.)

□ Một số hàm mất mát (loss function)

- *Regression loss*

Mean square error/Quadratic loss/L2 loss: $MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$

Mean absolute error/L1 loss: $MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$

Mean bias error: $MBE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)$

- *Classification loss*

Hinge loss/Multi class SVM loss, Cross entropy loss, ...



2. Gradient Descent (tt.)

□ Sử dụng ma trận giả nghịch đảo

Training set: $T = \{t^{(i)}\}_{i=1}^m, t^{(i)} = \langle x^{(i)}, y^{(i)} \rangle$

input $x^{(i)} \in R^n$

$$X = \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(m)} \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix}$$

output $y^{(i)} = y_i \in R$

$$Y = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Đặt: $x = (x_1, \dots, x_n) \in R^n, \hat{y} = f(x) = \sum_{j=1}^n w_j x_j + w_0$

$w^T = (w_1, \dots, w_n, w_0) \in R^{(n+1)}$

$\hat{x} = (x_1, \dots, x_n, x_0) \in R^{(n+1)}, x_0 = 1, \hat{y} = \hat{x} \cdot w$

$\hat{x}_i = (x^{(i)}, 1) \in R^{(n+1)}, y_i = y^{(i)}, \forall i = 1, m$

bias



2. Gradient Descent (tt.)

❑ Sử dụng ma trận giả nghịch đảo

Training set:

$$\hat{X} = \begin{pmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_m \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1n} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{m1} & \cdots & x_{mn} & 1 \end{pmatrix}, Y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Tìm vector cột: $w = (w_1, \dots, w_n, w_0)^T$ sao cho $\hat{y} = \hat{X} \cdot w \approx y$ tốt nhất

Hàm mất mát (*loss function*):

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2$$

Tìm optimal point:

$$w^* = \arg \min_w L(w)$$



2. Gradient Descent (tt.)

❑ Sử dụng ma trận giả nghịch đảo

Hàm mất mát (*loss function*):

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2$$

Tìm optimal point:

$$w^* = \arg \min_w L(w)$$

Xét:

$$\hat{X} = \begin{pmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_m \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1n} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{m1} & \cdots & x_{mn} & 1 \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$



2. Gradient Descent (tt.)

□ Sử dụng ma trận giả nghịch đảo

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2 \quad m = |T|$$

- Đạo hàm riêng của L theo w_i

$$\begin{aligned} L(w_i) &= (y_i - \hat{x}_i w)^2 = (y_i - \sum_{j=0}^n \hat{x}_j w_j)^2 = (y_i - (\hat{x}_i w_i + \sum_{j \neq i} \hat{x}_j w_j))^2 = \\ &= (y_i - (\hat{x}_i w_i + C_i))^2 = y_i^2 - 2y_i(\hat{x}_i w_i + C_i) + (\hat{x}_i w_i + C_i)^2 = \\ &= y_i^2 - 2y_i \hat{x}_i w_i - 2y_i C_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + C_i^2 = \\ &= -2y_i \hat{x}_i w_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + D_i \end{aligned}$$



2. Gradient Descent (tt.)

□ Sử dụng ma trận giả nghịch đảo

- Đạo hàm riêng của L theo w_i

$$L(w_i) = -2y_i \hat{x}_i w_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + D_i$$

$$\frac{\partial L(w_i)}{\partial w_i} = -2y_i \hat{x}_i + 2\hat{x}_i^2 w_i + 2\hat{x}_i C_i = 2\hat{x}_i \cdot (\sum_{j=0}^n \hat{x}_j w_j - y_i)$$

$$\frac{\partial L(w)}{\partial w} = \begin{pmatrix} \frac{\partial L(w)}{\partial w_1} \\ \frac{\partial L(w)}{\partial w_2} \\ \vdots \\ \frac{\partial L(w)}{\partial w_n} \end{pmatrix} = \frac{1}{m} \hat{X}^T (\hat{X} \cdot w - Y)$$



2. Gradient Descent (tt.)

□ Sử dụng ma trận giả nghịch đảo

$$\frac{\partial L(w)}{\partial w} = \frac{1}{m} \hat{X}^T (\hat{X} \cdot w - Y) = 0$$

Giải hệ phương trình, tìm w :

$$\underbrace{\hat{X}^T \cdot \hat{X}}_A \cdot w = \underbrace{\hat{X}^T \cdot Y}_B$$

- Nếu $\hat{X}^T \cdot \hat{X}$ khả nghịch: $w = (\hat{X}^T \cdot \hat{X})^{-1} \cdot \hat{X}^T \cdot Y$
- Nếu $\hat{X}^T \cdot \hat{X}$ KHÔNG khả nghịch: $w = (\hat{X}^T \cdot \hat{X})^{\dagger} \cdot \hat{X}^T \cdot Y$
với $(\hat{X}^T \cdot \hat{X})^{\dagger}$ là ma trận *giả nghịch đảo* của $\hat{X}^T \cdot \hat{X}$



Tài liệu tham khảo



Vũ Hữu Tiệp, *Machine Learning cơ bản*, 2018